

# **Sistemas de lógica borrosa evolutivos para robots de asistencia social, creativos y personalizados**

**Alberto García Martín y Erick José Mercado Hernández**



**VNiVERSiDAD  
D SALAMANCA**

Máster en Sistemas Inteligentes

Universidad de Salamanca

# Tabla de contenidos

<b>Resumen</b>	<b>3</b>
<b>Introducción</b>	<b>3</b>
<b>Técnicas aplicadas</b>	<b>4</b>
Un enfoque integrado basado en la IA para crear robots de asistencia social personalizados	4
EFS4SAR: Sistema de lógica borrosa evolutivo para SAR	6
<b>Casos de estudio y resultados obtenidos</b>	<b>7</b>
Pacientes simulados sintéticamente	7
Pacientes humanos con preferencias “borrosas”	12
<b>Conclusiones y futuras líneas de trabajo</b>	<b>14</b>
<b>Referencias</b>	<b>15</b>
<b>Fuente de información</b>	<b>15</b>

# Resumen

Los robots de asistencia social (SAR, por sus siglas en inglés) se utilizan cada vez más en el cuidado de personas con demencia y ancianos. Para proporcionar una asistencia efectiva, los SAR deben personalizarse para cada paciente, considerando la estimulación de su pensamiento divergente de formas creativas. Los sistemas de lógica borrosa basados en reglas son métodos efectivos para la toma de decisiones automatizada en SAR. Sin embargo, expandir y modificar las reglas de estos sistemas para adaptarse a las necesidades, preferencias y condiciones médicas cambiantes de los pacientes puede ser tedioso y costoso. En este artículo se presenta “EFS4SAR”, un sistema evolutivo de lógica borrosa para robots de asistencia social que apoya la evolución autónoma de las reglas borrosas que dirigen el comportamiento del SAR. EFS4SAR combina sistemas de lógica borrosa basados en reglas tradicionales con algoritmos evolutivos, que modelan el proceso de evolución en la naturaleza y han demostrado resultar en comportamientos creativos. EFS4SAR se evalúa mediante simulaciones informáticas con datos sintéticos y reales. Los resultados muestran que las reglas borrosas evolucionadas con el tiempo no solo se personalizan en función de las preferencias personales y las necesidades terapéuticas de los pacientes, sino que también cumplen con los criterios de originalidad y efectividad en las tareas terapéuticas propuestas a los pacientes. Comparado con otros sistemas borrosos evolutivos existentes, EFS4SAR logra una efectividad similar con un mayor grado de originalidad.

## Introducción

Los *robots de asistencia social* (SAR) están ganando popularidad en terapias no farmacológicas para el cuidado de la demencia, mostrando efectos positivos en el funcionamiento cognitivo, psicológico y global de los pacientes. Para garantizar la efectividad de estas terapias, es crucial personalizar el comportamiento de los SAR a cada paciente. Esta personalización puede ser a corto plazo, adaptándose durante sesiones individuales, o a largo plazo, teniendo en cuenta el contexto cultural y social en evolución del paciente, además de estimular regularmente su pensamiento divergente y capacidades cognitivas.

A pesar de la existencia de numerosas soluciones para la personalización a corto plazo, hay pocos trabajos sobre la personalización a largo plazo y la toma de decisiones de los SAR. Los enfoques existentes suelen estar adaptados a tareas específicas o dirigidos a grupos generales de usuarios. La lógica borrosa y los *sistemas de inferencia borrosa* (FIS) se han identificado como herramientas adecuadas para codificar y aprovechar el conocimiento cultural, social y médico necesario en las tomas de decisiones automatizadas de los SAR. Sin embargo, estos enfoques basados en lógica borrosa generalmente requieren un proceso tedioso para expandir y adaptar las reglas a nuevos casos.

En la última década, han surgido numerosas soluciones para la evolución automatizada de sistemas basados en reglas borrosas, conocidos como *sistemas borrosos evolutivos* (EFS). Estos sistemas son capaces de adaptarse y desarrollarse automáticamente para reflejar los cambios dinámicos en los datos de entrada. A pesar de su eficacia, estos sistemas tienen limitaciones, como la falta de generalización en las predicciones y el efecto de “desaprendizaje”. Para superar esto, la literatura reciente emplea algoritmos evolutivos como mecanismo subyacente para la evolución de los sistemas borrosos.

En este trabajo de (Dell’Anna et al.) se introduce EFS4SAR (*sistema de lógica borrosa evolutivo para robots de asistencia social*), un sistema de reglas borrosas evolutivas diseñado específicamente para la

personalización a largo plazo y la toma de decisiones creativas de SAR. EFS4SAR utiliza algoritmos genéticos para evolucionar autónomamente la base de reglas de un sistema borroso utilizado en la toma de decisiones de un SAR durante interacciones con pacientes. EFS4SAR introduce dinamismo en enfoques basados en reglas tradicionales para SAR, estimulando la creatividad y optimizando las reglas para personalizarlas al paciente particular.

EFS4SAR se distingue de otros EFS existentes en que evoluciona las reglas borrosas que dirigen el comportamiento de los SAR para que las actividades terapéuticas propuestas a los pacientes sean personalizadas, efectivas y diversas. Además, este trabajo presenta un enfoque novedoso para integrar EFS en la toma de decisiones y personalización a largo plazo de los SAR.

Los resultados experimentales de EFS4SAR con datos sintéticos y reales muestran que, además de las métricas estándar (precisión y número de reglas), EFS4SAR también cumple con las características clásicas de creatividad (originalidad y efectividad de las tareas terapéuticas propuestas).

## Técnicas aplicadas

### Un enfoque integrado basado en la IA para crear robots de asistencia social personalizados

En esta sección, se describe el enfoque que se propone para la personalización y toma de decisiones creativas y a largo plazo de los robots de asistencia social (SAR). Se distinguen tres fases, descritas en detalle a continuación, que tienen como objetivo respectivamente (i) proporcionar al SAR el conocimiento disponible sobre las preferencias personales, el estado físico y mental, y las necesidades del paciente, así como sobre las intervenciones terapéuticas relevantes para el paciente; (ii) dirigir el comportamiento del SAR durante las interacciones con los pacientes; (iii) utilizar el conocimiento adquirido durante las interacciones para evolucionar las reglas borrosas del SAR a través de EFS4SAR.

#### Fase de configuración humana

En la fase de configuración humana del enfoque de inteligencia artificial para SAR, un experto con conocimiento especializado, como un terapeuta, realiza una selección cuidadosa de categorías terapéuticas que se consideran significativas para un paciente en particular. Estas categorías podrían incluir áreas como estimulación cognitiva, terapia musical o de video, y ejercicios multimodales. El experto, utilizando su entendimiento del paciente, asigna pesos a estas categorías para establecer prioridades en las actividades del SAR.

Posteriormente, el experto crea un conjunto de reglas iniciales, conocidas como *reglas creativas* (reglas-c), que evolucionarán con el tiempo. Estas reglas se basan en el conocimiento existente del paciente, incluyendo normativas y guías de prácticas aceptadas en terapias. Estas reglas son esenciales para dirigir las acciones del SAR durante sus interacciones con el paciente. Se utilizan para relacionar información relevante sobre el paciente, como condiciones físicas y mentales, personales y preferencias, con actividades sugeridas por el SAR. Estas reglas iniciales se ajustan con el tiempo basándose en la experiencia adquirida en interacciones anteriores, lo que permite una personalización a largo plazo de las sugerencias del SAR.

## Fase de interacción

Durante una interacción, se activan ciertas reglas-c, que llevan a sugerencias de actividades específicas por parte del SAR, basadas en el vector de entrada recibido en ese momento. Por ejemplo, el SAR podría recomendar realizar una caminata de 40 minutos o jugar un juego de tres en raya con un nivel de dificultad determinado.

$$a_t^* = \arg \max_{a \in O_t} \left( \bar{e}_{a,t} \cdot w_{H_a} \cdot \frac{\sum_{r_a \in R_t^+} c_{r_a,t}}{|R_t^+|} \right)$$

Las actividades recomendadas pasan por un bloque de selección (selector de actividad), que elige la actividad óptima de un conjunto de posibles actividades. Esta selección se realiza maximizando una combinación de tres factores:

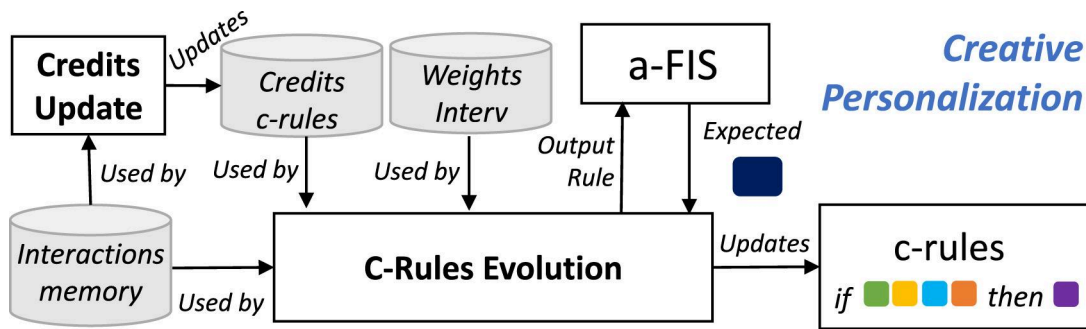
- **Retroalimentación esperada:** Es el valor medio de las salidas del a-FIS (FIS de asistencia) para una actividad en un tiempo específico, que se considera la retroalimentación esperada para la entrada dada al c-FIS (FIS de creatividad) y una actividad candidata.
- **Peso asociado a la categoría terapéutica:** Indica la importancia de la categoría terapéutica a la que corresponde la actividad.
- **Promedio de créditos de las reglas-c:** Es el promedio de los créditos de todas las reglas-c que contribuyeron a la sugerencia de la actividad en ese momento. Estos créditos son un valor numérico que representan la importancia y efectividad esperada de una regla.

Una vez seleccionada una actividad, el SAR la sugiere al paciente y asiste durante la tarea. Este proceso de sugerir y realizar una actividad con el paciente se denomina como un paso de una interacción. Durante el curso de una interacción, el SAR recibe retroalimentación implícita o explícita del paciente sobre las actividades propuestas, que se utiliza para dar nueva información a las reglas-c y reglas a para los siguientes pasos de la misma interacción y para personalizar las reglas-c para futuras interacciones.

Esta fase es crucial para la personalización a largo plazo de las sugerencias del SAR basada en la retroalimentación recibida. Se utiliza una memoria de interacciones que almacena tuplas con detalles de cada paso de interacción, incluyendo la actividad realizada, la retroalimentación esperada y realizada, y las fortalezas de disparo de las reglas en el c-FIS en ese momento.

## Fase de personalización creativa

En la fase de personalización creativa, el SAR aprovecha el conocimiento almacenado en la memoria de interacciones para hacer evolucionar las c-reglas. La evolución de las c-reglas se realiza entre diferentes interacciones (o sesiones) mediante el algoritmo EFS4SAR, que personaliza las actividades que se propondrán a los pacientes manteniendo un grado adecuado de variabilidad, lo que hace que las sugerencias del SAR sean “creativas”. Al final de la fase de personalización, las c-reglas más adecuadas encontradas con el algoritmo evolutivo sustituyen a las actuales en el c-FIS y se utilizan para dirigir el comportamiento del SAR durante las siguientes interacciones.



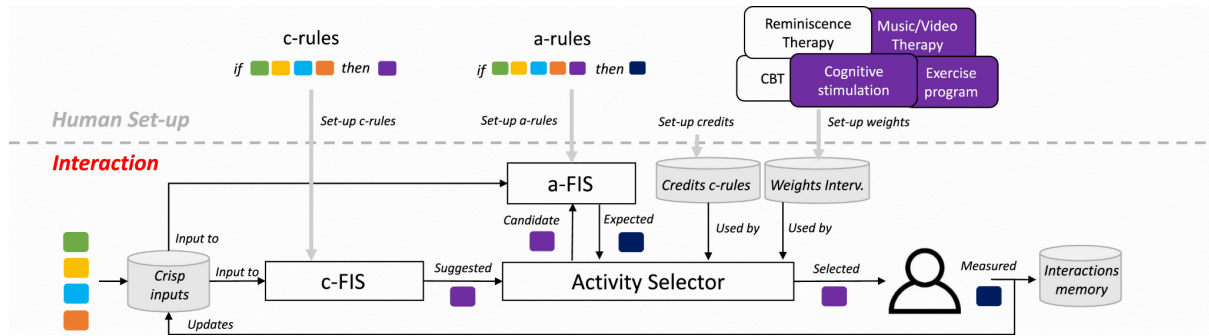
## EFS4SAR: Sistema de lógica borrosa evolutivo para SAR

En esta sección se describe EFS4SAR, el método propuesto para evolucionar las reglas borrosas que determinan los comportamientos posibles de los SAR. EFS4SAR adopta un algoritmo genético que se basa en los créditos asignados a las reglas y actualizados con el tiempo. Primero, se detalla el procedimiento de actualización de los créditos de las reglas. Luego, se explica cómo se codifica una regla-c borrosa como un cromosoma binario y se define la aptitud de un cromosoma que representa una regla-c. Finalmente, se describe el procedimiento para la evolución de las reglas-c a través de algoritmos genéticos.

La actualización de los créditos se inspira en los sistemas clasificadores de Holland [1], donde el crédito de una regla se actualiza para reflejar la respuesta de los pacientes a la actividad propuesta, siendo proporcional a la contribución de la regla a la decisión tomada por el SAR. En cuanto a la codificación de las reglas-c borrosas como cromosomas binarios, se sigue el enfoque de Michigan [2], donde cada individuo en la población del algoritmo genético representa una regla-c, y la población de una generación representa una base de reglas candidatas. Esto se debe a su eficiencia computacional y a la facilidad para refinar la aptitud de reglas individuales basándose en la retroalimentación recibida.

La aptitud de una regla-c borrosa se calcula utilizando cuatro factores diferentes, reflejando la efectividad esperada de la actividad propuesta por la regla, basándose en la experiencia adquirida con el paciente y las indicaciones terapéuticas proporcionadas por el terapeuta, mientras que un término asegura que las reglas que se repiten demasiado obtengan una menor aptitud. Se adopta un enfoque de Monte Carlo para evaluar las reglas-c, considerando el universo completo de discurso de las variables de entrada.

Finalmente, la evolución de las reglas-c se realiza aplicando un algoritmo genético. La mejor población de reglas-c se selecciona según sus valores de aptitud, excluyendo reglas duplicadas o inválidas. La diversidad de la base de reglas-c se mide utilizando el índice de Gini-Simpson [3], reflejando cuántos tipos diferentes de categorías terapéuticas y actividades están cubiertos por la población. El objetivo es evitar bases de reglas que siempre sugieren la misma actividad para una categoría dada o que incluyan reglas muy variadas en términos de actividades, pero todas pertenecientes a la misma categoría terapéutica.



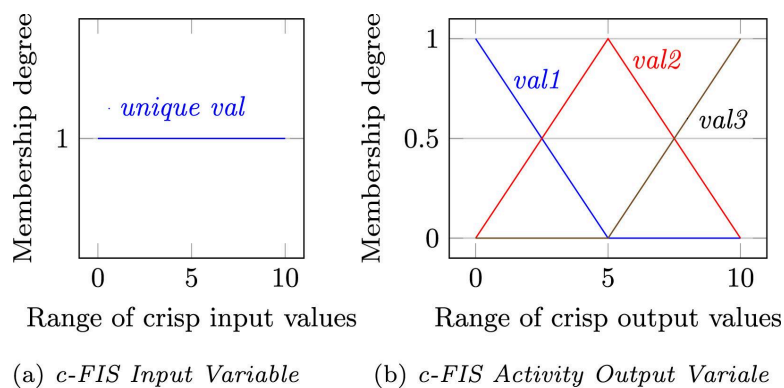
## Casos de estudio y resultados obtenidos

### Pacientes simulados sintéticamente

Inicialmente, se realizan simulaciones con dos agentes: el SAR, que implementa los enfoques de toma de decisiones y personalización propuestos en este artículo, y el Paciente, que reacciona a la actividad sugerida por el SAR según sus propias preferencias, inicialmente desconocidas para el SAR. Nótese que en el resto de esta sección, SAR y Paciente se utilizan indistintamente para agente SAR y agente Paciente. Un paso de simulación define un paso de interacción entre el SAR y el Paciente durante el cual una actividad (se consideran interacciones compuestas por un paso) es sugerida por el SAR, y la retroalimentación correspondiente es recibida del Paciente.

Se da un peso unitario a todas las categorías terapéuticas del conjunto, y se deja vacía la base de reglas del a-FIS. Por lo tanto, a través de las simulaciones se evalúa si SAR puede personalizar sus decisiones para el paciente en un número finito de interacciones basadas únicamente en la respuesta inmediata del paciente, y sin conocimiento previo sobre el paciente (es decir, una base de reglas vacía para el a-FIS).

En los experimentos, se utilizan operadores borrosos estándar para la inferencia borrosa. En concreto, se utiliza el operador mínimo para determinar la certeza de las premisas y calcular las funciones de pertenencia implícitas del consecuente de las reglas en el motor de inferencia del c-FIS, y se emplea el método del centro de gravedad para la “deborrosificación”. Esta elección está motivada por el hecho de que se considera un caso en el que las funciones de pertenencia son invariantes en el tiempo, de modo que el uso de diferentes operadores solo afectaría mínimamente a los resultados de los experimentos, que se centran en evaluar la personalización y originalidad de las actividades sugeridas por SAR a los Pacientes.



Al principio de su paso de simulación, SAR recibe valores muestreados aleatoriamente para sus variables de entrada y sugiere una actividad al paciente utilizando el c-FIS. Cada paciente devuelve un valor (donde 0 indica una respuesta extremadamente negativa y 10 una extremadamente positiva) en respuesta a la actividad sugerida por SAR. Dado que lo importante es la personalización de las decisiones de SAR, el componente central es una única respuesta numérica que proporciona información tanto sobre las preferencias del paciente como sobre la eficacia de una determinada actividad terapéutica de forma agregada. Sin embargo, se admiten múltiples medidas de retroalimentación.

Inicialmente, es asignado aleatoriamente por el paciente a las actividades propuestas en el 60% de los casos  $f < 5$  y en el 40% restante de los casos  $f \geq 5$ . Al hacerlo, se modela el hecho de que algunas intervenciones terapéuticas son más eficaces para un paciente (ya sea por las preferencias de los pacientes o por el resultado terapéutico), mientras que otras son menos eficaces. Cada vez que la misma actividad es sugerida por SAR, el Paciente ajusta la retroalimentación previa según su tipo, una característica definida por Paciente que determina cómo reacciona ante sugerencias repetidas de la misma actividad a lo largo del tiempo. En concreto, se consideran pacientes que tienen una memoria de tamaño (es decir, recuerdan las sugerencias realizadas por SAR en los 14 pasos de simulación anteriores). Dada una actividad, cada Paciente devuelve una respuesta determinada por:

$$f \leftarrow f + \Delta f(n_{a,m}) \quad (7)$$

where

$$\Delta f(n_{a,m}) = \begin{cases} \lambda n_{a,m}, & \text{if } 0 \leq n_{a,m} \leq \tau_1. \\ \lambda \tau_1, & \text{if } \tau_1 < n_{a,m} \leq \tau_2. \\ \lambda \tau_1 - \frac{\lambda \tau_1}{\tau_3 - \tau_2} (n_{a,m} - \tau_2), & \text{if } \tau_2 < n_{a,m} \leq \tau_3. \\ -\lambda (n_{a,m} - \tau_3), & \text{if } n_{a,m} > \tau_3. \end{cases} \quad (8)$$

Cada paciente simulado en la simulación se caracteriza por cuatro parámetros,  $\Delta$ ,  $N$ ,  $M$  (con  $M \leq N$ ) y  $\alpha$ . La dinámica de cómo un paciente responde a las actividades sugeridas por el SAR se basa en estos parámetros:

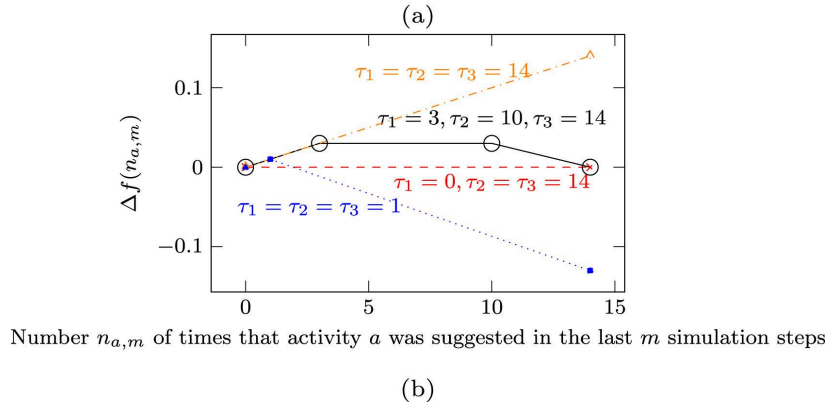

**Retroalimentación basada en la repetición de actividades:** Si una actividad no fue sugerida en los últimos  $N$  pasos de simulación, ( $M=0$ ), el paciente devuelve la misma retroalimentación que la última vez para esa actividad o, si es la primera vez, una retroalimentación aleatoria. Si la actividad ya fue sugerida, pero no más de  $M$  veces ( $M < N$ ), el paciente aumenta la retroalimentación previamente dada por  $\alpha$ .

**Cambios en la retroalimentación:** El valor de  $\alpha$  indica la rapidez con la que cambia la retroalimentación del paciente. Si  $M < N$ , el paciente incrementa constantemente la retroalimentación, lo que sugiere que disfruta cada vez más de la actividad. Cuando  $M=N$ , el aumento en la retroalimentación se reduce. Si  $M > N$ , el signo de  $\alpha$  cambia.

**Caracterización de diversos tipos de pacientes:** Diferentes combinaciones de  $\Delta$ ,  $N$ ,  $M$  y  $\alpha$  permiten simular una variedad de pacientes con comportamientos y dinámicas muy diferentes. Por ejemplo, un paciente puede disfrutar repitiendo la misma actividad varias veces o puede molestarse por demasiadas repeticiones.



**Visualización en el documento:** La siguiente figura ilustra la función dada por la ecuación (8) para valores no nulos y desiguales de  $\Delta$ . La figura muestra ejemplos de cuatro tipos de pacientes creados con diferentes combinaciones de estos cuatro parámetros, representando diversas tendencias y reacciones a la repetición de actividades.



## Métricas para la personalización creativa.

Para cuantificar estos aspectos, se utilizan dos métricas principales: retroalimentación y repeticiones.

- **Retroalimentación:** Esta métrica se refiere a la retroalimentación proporcionada por el paciente al SAR, tal como se describe en la fórmula (7) del documento. Se analiza tanto el promedio como la tendencia de la retroalimentación a lo largo de la simulación. Un SAR que aprende efectivamente las preferencias del paciente y la efectividad de diferentes intervenciones terapéuticas, y personaliza su toma de decisiones en consecuencia, resultará en valores de retroalimentación que tienden a 10.
- **Repeticiones:** Esta métrica mide el número de actividades en los últimos pasos de la simulación, que son idénticas a la actividad sugerida en el paso de simulación actual. Se analiza el número promedio de repeticiones en la simulación, utilizando la fórmula (9) del documento. En esta fórmula,  $L$  es el número de pasos de simulación y  $Ri, j$  es el número de veces que la actividad  $i$  sugerida en el paso de simulación  $j$  fue sugerida en los pasos de simulación anteriores.

$$\rho = \frac{\sum_{i \in [1, s]} n_{a_i, m}}{s} \quad (9)$$

Estas dos métricas están alineadas con los criterios de efectividad (es decir, rendimiento satisfactorio) y originalidad que caracterizan la creatividad según la definición estándar propuesta por Runco y Jaeger [4]. La retroalimentación es una medida de la efectividad de la personalización, ya que determina la utilidad, adecuación y pertinencia de las actividades sugeridas. Las repeticiones son una

medida de la originalidad de la personalización, ya que cuantifican la unicidad y diversidad de las actividades propuestas a lo largo del tiempo. Un SAR creativo que funciona según lo previsto resultará en altos valores de retroalimentación y bajas repeticiones

### Configuración experimental.

- **Importancia del índice de diversidad:** Se comparan los sistemas de toma de decisiones  $S$  y  $S'$  para estudiar la importancia del índice de diversidad en la elección de la mejor población. EFS4SAR se implementa con y sin un índice de diversidad, con valores de  $\lambda=0.5$  y  $\lambda=0$  respectivamente.
- **Robustez del sistema de toma de decisiones:** Se examina la robustez del sistema  $S$  cuando la retroalimentación recibida por el paciente está afectada por ruido, que puede deberse a errores en los sensores, imprecisión en las pruebas realizadas con los pacientes o la incapacidad de los pacientes para comunicar claramente su retroalimentación.

Para el ruido, se consideran tres tipos de ruido aplicados a la retroalimentación del paciente, ruido gaussiano, obtenido de un cambio en la retroalimentación muestreada de una distribución normal con media  $\mu=0$  y desviación estándar  $\sigma=2$ , limitada a un mínimo y un máximo. Ruido gaussiano inverso, que se obtiene generando primero un ruido gaussiano temporal y luego aplicando una regla específica para obtener el ruido final. Y finalmente ruido de retroalimentación invertido, que obtiene como  $10-f$ , con  $f$  siendo la retroalimentación del paciente. Para cada tipo de ruido, se prueban dos escenarios: “Ruido 0.2”, donde el ruido se genera con una probabilidad de 0.2, y “Ruido 1”, donde el ruido se aplica a toda la retroalimentación recibida.

Como línea base, se considera un sistema que elige aleatoriamente sus reglas- $c$  mediante una simulación. Este sistema se espera que tenga pocas repeticiones, pero también baja retroalimentación.

Se consideran 10 sistemas diferentes de toma de decisiones, y se sintetizan aleatoriamente 200 pacientes, muestreando uniformemente sus parámetros. Para cada sistema de toma de decisiones, se ejecutan 200 simulaciones diferentes, cada una simulando una secuencia de interacciones.

Decision-making system	$S$	$S_B$	$S_R$	$S_D$	Noise
$\beta$	0.04	0	0.04	0.04	0.04
$\eta$	10	1	1	10	10
$z_{a,n}$	7	-	-	7	7
$\gamma$	0.5	0	0.5	0	0.5
Noise type	-	-	-	-	$\{g, ig, r\}$
Noise prob.	0	0	0	0	$\{0.2, 1\}$

(a)

Parameter	Val	Parameter	Val
Mating top %	80%	Generations	50
Selection type	sss	Samples $N$	1
Crossover type	uniform	Inputs c-FIS	1
Crossover prob.	1	Outputs c-FIS	117
Mutation prob.	0.25	Possible activities	117
$\kappa$	0.75	Possible therapies	7
Rules	20	Memory size $m$	14
Default credit rule	1	Simulations	200 (5x each)
$w_{\bar{h}}$	$1 \forall h \in H$	Interactions/Sim	4000
Big $M$	100	Steps/Interactions	1
Domain feedback $f[0, 10]$	Payoff $q_i$ for $f$		$\alpha \cdot f^{1.8}$ , with $\alpha = 1$ if $f \geq 5$ , $\alpha = -1$ else

(b)


## Resultados

Se analizan 4000 pasos de interacción entre el SAR y uno de los 200 pacientes sintetizados aleatoriamente, y cada simulación se repite 5 veces. Los resultados confirman que el sistema propuesto se comporta según lo previsto con una variedad de pacientes, ofreciendo un buen equilibrio entre personalización y variedad en las sugerencias dadas.

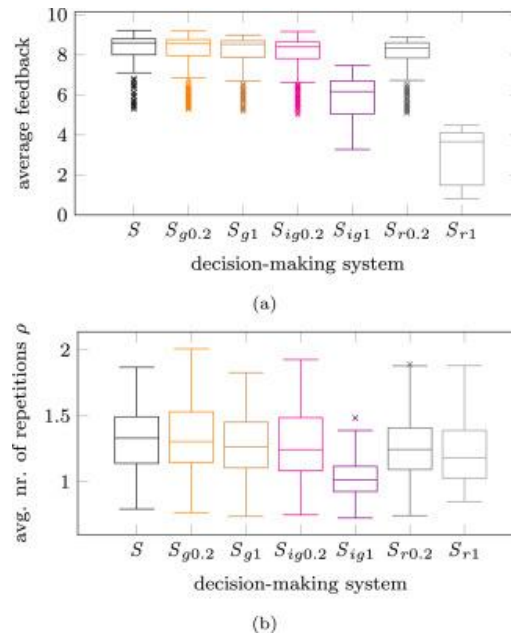
Los resultados proporcionan información estadísticamente relevante sobre una variedad de condiciones. Se determinó que 4000 pasos eran necesarios para garantizar que el SAR alcanzará un comportamiento estable. Los valores de los parámetros se ajustaron mediante experimentación extensa y un método de búsqueda en cuadrícula para explorar combinaciones de valores.

La siguiente tabla presenta el promedio y la desviación estándar de la retroalimentación y las repeticiones para los diferentes sistemas. Se reportan los efectos sobre la retroalimentación y las repeticiones comparando con el sistema de toma de decisiones de referencia. La ausencia de un símbolo de estrella indica la falta de una diferencia significativa en el sistema de toma de decisiones de referencia.

System	Feedback	Effect on feedback $S$	Repetitions	Effect on repetitions $S$
$S$	$8.17 \pm 1.00$		$1.32 \pm 0.24$	
$S_B$	$4.50 \pm 0.18$	Large (5.103)**	$0.13 \pm 0.01$	Large (7.103)**
$S_R$	$6.47 \pm 1.53$	Large (1.314)**	$5.34 \pm 2.28$	Large (2.477)**
$S_D$	$8.17 \pm 1.04$	None (0.000)	$1.38 \pm 0.27$	Small (0.216)**
$S_{g0.2}$	$8.12 \pm 1.02$	None (0.041)**	$1.34 \pm 0.26$	None (0.057)
$S_{g1}$	$8.03 \pm 1.03$	None (0.131)**	$1.28 \pm 0.22$	None (0.188)
$S_{ig0.2}$	$7.99 \pm 1.01$	None (0.177)**	$1.28 \pm 0.25$	None (0.179)*
$S_{ig1}$	$5.83 \pm 1.09$	Large (2.234)**	$1.03 \pm 0.14$	Large (1.496)**
$S_{r0.2}$	$7.95 \pm 1.01$	Small (0.219)**	$1.26 \pm 0.24$	Small (0.287)**
$S_{r1}$	$2.88 \pm 1.35$	Large (4.451)**	$1.22 \pm 0.23$	Small (0.440)**



Esta figura ilustra (a) la retroalimentación promedio de los pacientes, (b) el número promedio de actividades idénticas sugeridas por cada 14 pasos de simulación, y (c) la tendencia de la retroalimentación promedio.



Esta figura muestra los diagramas de caja que ilustran (a) la retroalimentación promedio del paciente y (b) el número promedio de actividades idénticas sugeridas al paciente por cada 14 pasos de simulación. Estos resultados corresponden al uso del sistema de toma de decisiones propuesto en 200 simulaciones, cada vez con diferentes tipos de ruido (ruido gaussiano, gaussiano invertido y retroalimentación invertida).

**Importancia del coste de repetición:** El sistema de toma de decisiones que ignora el coste de repetición tiende a priorizar la explotación, es decir, sugerir repetidamente las actividades que se sabe que son preferidas por el paciente, en detrimento de la exploración de nuevas actividades. Esto no siempre conduce a la máxima retroalimentación, ya que el paciente puede comenzar a disminuir su retroalimentación si ocurren demasiadas repeticiones. Los resultados muestran que considerar el coste de repetición es fundamental no solo para proporcionar sugerencias variadas (bajas repeticiones) sino también efectivas (alta retroalimentación).

**Importancia del índice de diversidad:** Ignorar el índice de diversidad conduce a un aumento en el número de repeticiones y a una retroalimentación casi idéntica. Considerar el índice de diversidad en el sistema de toma de decisiones propuestas mejora significativamente el número de repeticiones (ya bajo) en aproximadamente un 4.5%, sin disminuir la retroalimentación.

**Robustez ante el ruido:** Al considerar el ruido gaussiano, el tamaño del efecto en la retroalimentación y las repeticiones es insignificante, tanto cuando se aplica en el 20% de los casos como en cada paso de la simulación. Con ruido gaussiano invertido y ruido de retroalimentación invertido en el escenario “Ruido 1”, el impacto es mayor, indicando que el ruido afecta significativamente los créditos otorgados a las reglas-c y, por lo tanto, las decisiones del SAR.

## Pacientes humanos con preferencias “borrosas”

En esta sección, se compara EFS4SAR con sistemas borrosos evolutivos (EFS) de vanguardia, reduciendo la tarea del SAR (es decir, recomendar una actividad al paciente) a una tarea de clasificación de flujo de datos. Para evaluar los EFS en datos relevantes y realistas para SAR, se

utilizan 15 conjuntos de datos que caracterizan preferencias humanas reales sobre actividades diarias, obtenidas a través de una encuesta con participantes humanos.

La siguiente tabla muestra los EFS seleccionados para compararlos con EFS4SAR. Las columnas EA y MOEA indican, respectivamente, si el EFS está basado en algoritmos evolutivos y en algoritmos evolutivos multi-objetivo. La columna “# rules”, indica el método utilizado para determinar el número de reglas.

EFS	Year	EA	MOEA	# rules
SAFLS (Gu and Shen, 2021)	2021	No	No	min. # clusters
FWAAdaBoostSOFIES (Gu and Angelov, 2021)	2021	No	No	# classes
MEEFIS (Gu, 2021)	2020	Yes	No	avg nr. layers
PSO-ALMMo (Gu et al., 2021)	2020	Yes	No	# classes
SKMOEFS-MPAES_RCS (Gallo et al., 2020, Antonelli et al., 2014)	2020	Yes	Yes	minimized
ANFIS-GA (Moayedi et al., 2020)	2018	Yes	No	fixed
ANFIS-PSO (Moayedi et al., 2020)	2018	Yes	No	fixed
ALMMo-0 (Angelov et al., 2018)	2017	No	No	# classes
eTS-LS-SVM (Komijani et al., 2012)	2012	No	No	min. # clusters

La encuesta se realizó con 15 participantes, quienes indicaron sus actividades preferidas en diferentes circunstancias. Las preferencias se utilizaron para construir un modelo de cada participante en forma de un sistema de inferencia borrosa, que genera flujos de datos utilizados en los experimentos. Cada sistema de inferencia borrosa (FIS) tiene tres variables de entrada ambientales y una variable de salida, con valores lingüísticos que representan la retroalimentación. Los datos generados consisten en tuplas de valores nítidos muestreados al azar para las variables de entrada, y una actividad preferida.

Un ejemplo de dos posibles preferencias en lenguaje natural y su correspondiente traducción en reglas difusas se puede ver en la siguiente tabla.

Preference	Fuzzy Rule
when it's <b>sunny</b> and it's a <b>free day</b> I <b>love</b> <b>to exercise</b>	IF <i>weather</i> is <i>sunny</i> AND <i>day-type</i> is <i>free</i> AND <i>to-exercise</i> is <i>performed</i> THEN <i>feedback</i> is <i>very high</i>
when it's a <b>rainy morning</b> during a <b>working day</b> I <b>do not like</b> <b>to work from the office</b>	IF <i>weather</i> is <i>rainy</i> AND <i>day-type</i> is <i>working</i> AND <i>day-time</i> is <i>morning</i> AND <i>to-work-from-the-office</i> is <i>performed</i> THEN <i>feedback</i> is <i>low</i>

Los resultados experimentales comparan EFS4SAR con varios EFS de vanguardia en términos de precisión, número de reglas, retroalimentación y repeticiones. Se observa que los EFS más recientes proporcionan, en general, mayor precisión que los antiguos y EFS4SAR. Sin embargo, estos EFS tienden a repetir la misma sugerencia para puntos de datos similares, lo que resulta en una falta de originalidad. EFS4SAR, por otro lado, propone una variedad de actividades, personalizadas a los pacientes y considerando la necesidad de estimulación regular de la cognición. Además, EFS4SAR muestra una mayor retroalimentación cuando se consideran las preferencias cambiantes de los pacientes.

	<b>accuracy</b>	<b># rules</b>	<b>feedback<sub>s</sub></b>	<b>feedback<sub>m</sub></b>	<b>repetitions</b>
<b>random</b>	0.04±0.02	–	6.49±0.16	7.24±0.32	0.57±0.20
<b>EFS4SAR</b>	0.14±0.05	20.00±0	7.32±0.38	7.92±0.35	1.49±0.37
<b>SAFLS</b>	0.44±0.16	20.53±2.14	8.72±0.43	6.43±1.82	4.70±1.62
<b>FWAada</b>	0.34±0.16	28.40±13.08	8.37±0.39	7.84±1.88	3.16±1.72
<b>MEEFIS</b>	0.40±0.14	27.57±6.00	8.60±0.43	6.23±2.54	5.53±2.99
<b>PSO-ALMMo</b>	0.08±0.05	28.40±13.08	6.93±0.42	7.35±1.26	3.10±0.90
<b>SKMOEFS</b>	0.42±0.15	11.49±4.93	8.64±0.42	6.85±2.24	4.71±1.82
<b>ANFIS-GA</b>	0.07±0.05	28.40±13.08	6.78±0.52	6.51±1.85	3.89±1.35
<b>ANFIS-PSO</b>	0.07±0.04	28.40±13.08	6.82±0.44	6.60±1.78	3.74±1.36
<b>ALLMo-0</b>	0.22±0.10	28.40±13.08	7.83±0.31	8.05±0.67	1.53±0.80
<b>eTS-LS-SVM</b>	0.10±0.12	1.00±0	6.94±1.63	2.36±1.95	10.48±3.19

En términos de interpretabilidad, los EFS que determinan el número de reglas basado en el número de clases tienen un mayor número de reglas. SKMOEFS se destaca por optimizar con eficacia la precisión y el número de reglas. En EFS4SAR, el número de reglas-c es un parámetro que puede fijarse o variarse con el tiempo, y en los experimentos se utilizó un total de 20 reglas para todos los conjuntos de datos, demostrando que se pueden obtener resultados satisfactorios con un bajo número de reglas, incluso cuando el número de clases/actividades es más alto.

## Conclusiones y futuras líneas de trabajo

El objetivo principal de este estudio es proporcionar, a través de un proceso creativo, un equilibrio entre la comodidad/satisfacción de los pacientes y el valor terapéutico (en términos de estimulación cognitiva) de proponer una variedad de actividades. Se han cuantificado estos aspectos a través de dos métricas llamadas retroalimentación y repeticiones. La retroalimentación es proporcionada por el paciente al SAR.

Se han analizado tanto el promedio como la tendencia de la retroalimentación a lo largo de la simulación. Un SAR que puede aprender efectivamente las preferencias del paciente y la efectividad de diferentes intervenciones terapéuticas y personalizar su toma de decisiones, en consecuencia resultará en valores de retroalimentación que tienden a 10. Las repeticiones miden el número de

actividades en los últimos pasos de simulación, que son idénticas a la actividad sugerida en el paso de simulación actual. Se han analizado el número promedio de repeticiones en la simulación. Estas dos métricas, retroalimentación y repeticiones, están en línea con los dos criterios (efectividad, es decir, rendimiento satisfactorio y originalidad, respectivamente) que caracterizan la creatividad según la definición estándar propuesta por Runco y Jaeger [4].

## Referencias

1. Geyer-Schulz A., Holland classifier systems, Griffiths M., Whitehouse D. (Eds.), Proceedings of the 1995 International Conference on Applied Programming Languages, APL 1995, San Antonio, Texas, USA, June 4-8, 1995, ACM (1995), pp. 43-55
2. Valenzuela-Rendón M., The fuzzy classifier system: A classifier system for continuously varying variables, Belew R.K., Booker L.B. (Eds.), Proceedings of the 4th International Conference on Genetic Algorithms, San Diego, CA, USA, July 1991, Morgan Kaufmann (1991), pp. 346-353
3. Jost L., Entropy and diversity, *Oikos*, 113 (2) (2006), pp. 363-375
4. Runco M.A., Jaeger G.J., The standard definition of creativity, *Creativity Res. J.*, 24 (1) (2012), pp. 92-96

## Fuente de información

Davide Dell'Anna, Anahita Jamshidnejad, Evolving Fuzzy logic Systems for creative personalized Socially Assistive Robots, *Engineering Applications of Artificial Intelligence*, Volume 114, 2022, 105064, ISSN 0952-1976, <https://doi.org/10.1016/j.engappai.2022.105064>.  
(<https://www.sciencedirect.com/science/article/pii/S0952197622002251>)